


# DeepLearning研究の歴史的背景

AP1 清野憲彰

# DeepLearning研究の歴史

# DeepLearning研究の歴史

- 1940年～1950年の研究
  - 1943年 Threshold Logic Unit(TLU) [McCulloch, Pitts]
    - 人口ニューロンの原型となる数理モデルの提案
    - 形式ニューロン (formal neuron) 、ヘヴィサイド関数を使用



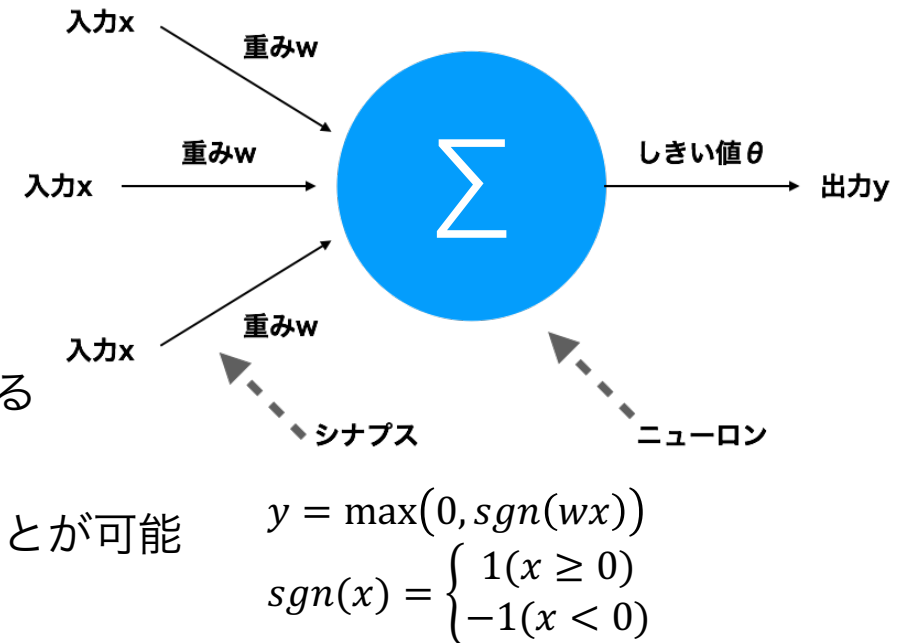
$$y = \begin{cases} 1 & \text{if } sum \geq \theta \\ 0 & \text{if } sum \leq \theta \end{cases}$$

# DeepLearning研究の歴史

- 1940年～1950年の研究
  - 1949年 Hebbian learning rule [Hebb]
    - ニューロンの学習メカニズムの提唱（ヘブの学習則, ヘブ則）
    - あるニューロンの発火が他のニューロンを発火させる時、この2つのニューロンは結合が強くなる  
→ 記憶した！
  - 後に多くの実験でこの仮説が実証されていく

# DeepLearning研究の歴史

- 1950年～1960年の研究
  - 1958 年 Perceptron [Rosenbaltt]
    - 学習可能なニューロンの数理モデルを提案
    - 単純パーセプトロン (Simple Perceptron)
      - 教師データを元に重みwを自動的に求める
        - 教師あり学習
      - 誤り訂正学習則により重みを計算することが可能
    - 学習能力を持つパターン認識器
    - ステップ関数を使用
    - 教師が線形分離可能であれば
      - 学習が収束する
      - 教師データのすべてのデータを正しく分類可能




# DeepLearning研究の歴史

- 1950年～1960年の研究
  - 1958 年 The Mark I Perceptron [Rosenbaltt, Wightman他]
    - 画像認識用のパーセプトロン
  - 1960年 ADALINE [Widrow, Hoff]
    - Perceptronを改良
  - 1962年 Perceptron convergence theorem [Rosenbaltt]
    - 線形分離可能であれば教師データをすべて正しく分類することが可能


# DeepLearning研究の歴史

- パーセプトロンの欠点
  - 耐ノイズ性に欠く
  - 学習の収束が非常に遅い
  - 線形分離不可能な問題では学習が収束しない [1969年 Minsky, Papert]
    - 現実世界には線形分離不可能な問題が非常に多い

→ 研究が下火になる



線形分離可能問題




線形分離不可能問題

# DeepLearning研究の歴史

- 1980年代の研究

- 1986年 Multi-Layer Perceptron [Rumelhart, Hinton, Williams]
  - 複数のニューロンを接続し, 多層にしたネットワーク
  - 学習は最急降下法と誤差逆伝搬法




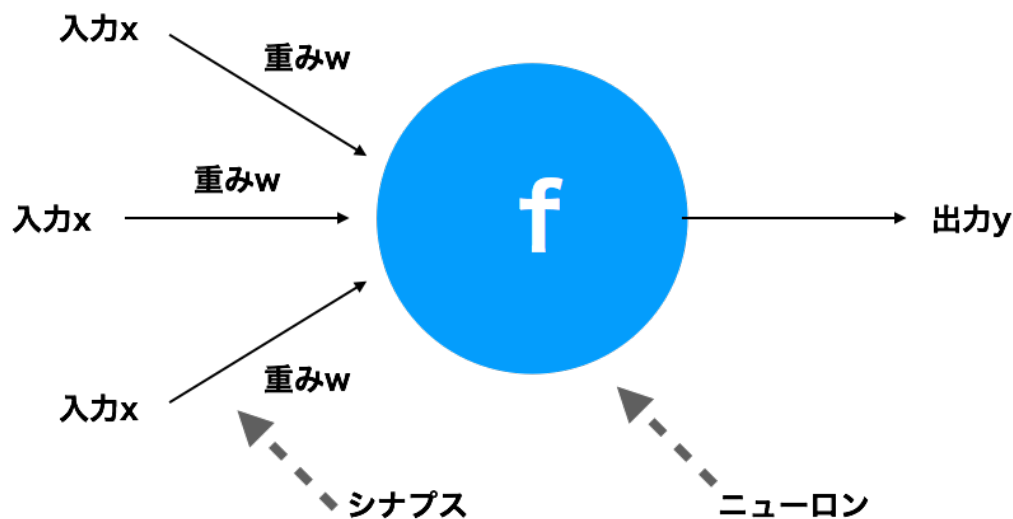


# DeepLearning研究の歴史

- 1980年代の研究

- 1986年 Multi-Layer Perceptron [Rumelhart, Hinton, Williams]

- 誤差逆伝播法では各ニューロンの勾配を使う
      - 従来までのステップ関数, ヘヴィサイド関数では微分不可能
      - シグモイド関数を導入することで微分項を導出可能に



# DeepLearning研究の歴史

- 1980年代の研究

- 1989年 万能近似能力 [Cybenko]

- 隠れ層に十分な数のニューロンがあれば2層のニューラルネットワークは任意の連続関数を十分に近似することが出来る

- 仮説

- 隠れ層を2層より多くすることでより複雑な問題を解けるようになるのでは？

→結論はNo


- 多層にすると勾配消失問題が重大化
    - 誤差が入力層近くまで伝播しない
  - 過学習の発生, 局所最適解, 鞍点
    - それでも耐ノイズ性は上がりません

# DeepLearning研究の歴史

## • 1980年代の研究

### • 1980年 ネオコグニトロン[福島邦彦]

- 生理学的知見から考案
- 視覚野の複雑細胞(C細胞)の層と単純細胞(S細胞)の層とが交互に並ぶ構造
- 手書き数字の認識タスクに適用
  - これまでになかった高い精度で分類することが可能であると判明
- 現在のCNNの原型
- 活性化関数はRectified linier関数
  - 現在もReLU関数として利用される



# DeepLearning研究の歴史

- 1980年～1990年の研究
  - 1982年 自己組織化マップ [T.Kohonen]
  - 1985年 ボルツマンマシン [D.H.Ackleyら]
  - 1986年 制限ボルツマンマシン [P.Smolensky]
  - 1988年 AutoEncoder [G.W.Cottrellら]
  - 1989年 LeNet [Y.LeCunら]
    - 誤差逆伝搬法を用いた畳み込みニューラルネットワーク
    - 32x32の手書き文字を畳み込み層2層, プーリング層2層, 全結合相3層で分類
    - 耐ノイズ性, 高い分類精度

# DeepLearning研究の歴史


- 2000年代の研究
  - GPUテクノロジーの劇的な進歩
    - NVIDIA社がCudaを発表
    - ニューラルネットの計算を並列化・高速化
      - 学習速度の爆発的な進化
      - 多層のネットワークでも現実的な時間で学習可能に

# DeepLearning研究の歴史

- 2000年代の研究
  - 2006年 RBMと教師なし事前学習 [Hinton, Salakhutdino]
    - 浅いNNで良い初期値を学習, 深いNNに良い初期値を入れて教師あり学習すると精度が向上
  - 2011年 ReLU関数 [Nair, Hinton]
    - シグモイドの代わりにランプ関数を使うことで勾配消失問題が解消
    - 深いネットワークでも学習が可能になる
  - 2012年 Dropout [Hintonら]
    - 確率的にニューロンを欠落させることで自由度を制限
    - 過学習を抑制

# DeepLearning研究の歴史

- 2000年代の研究
  - ILSVRC2012
    - 1000種類の画像に写っている物体を識別するコンペ
    - Krizhevsky, Ilya, HintonらがAlexNetを発表



# DeepLearning研究の歴史

- 2000年代の研究

- 2013年

- Deep Q-Learning [Mnih et al, NIPS'13]
      - 教科学習の枠組みをNNに適用
      - アタリのクラシックゲームで人間を圧倒
    - word2vec [T.Mikolovら]
      - 文字の離散表現の獲得

- 2014年

- GoogleNet [Szegedyら]
      - 22層の畳み込み層を独自のフレームワークで学習
    - VGG-Net[Simonyanら]
      - 16, 19層の畳み込み層で画像認識を高精度で達成
    - Generative Adversarial Network [Goodfellowら]
      - データ生成モデル



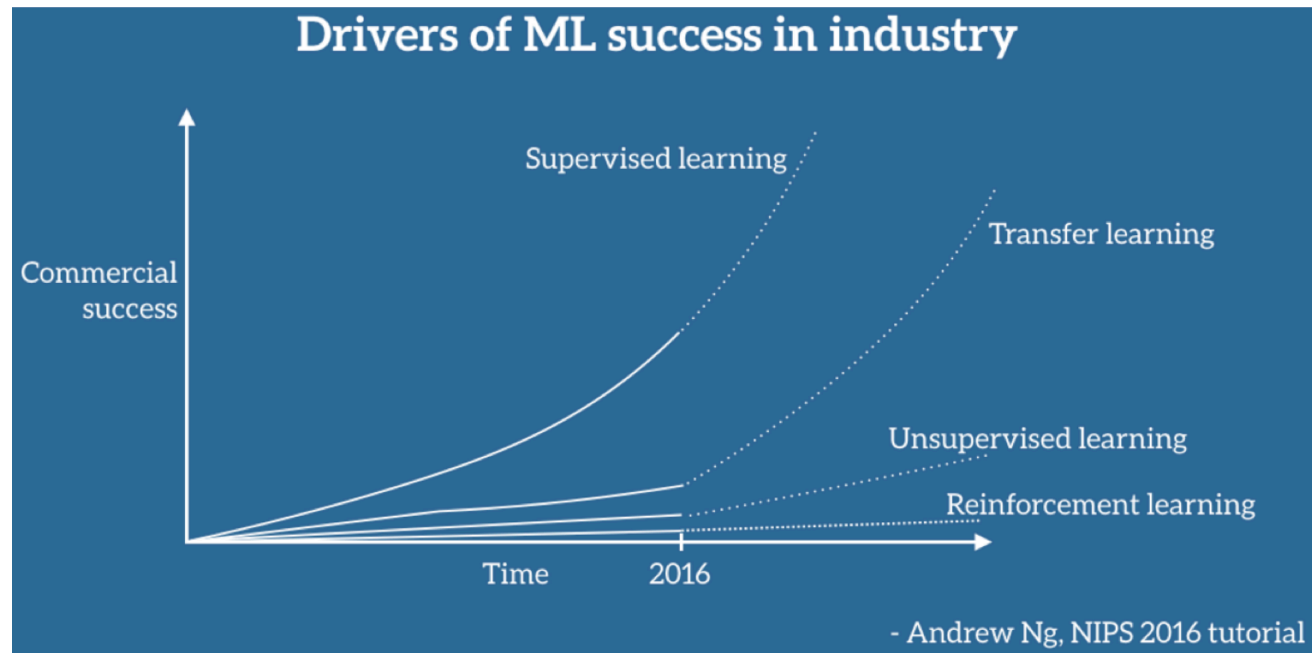
# DeepLearning研究の歴史

- 2000年代の研究
  - 2015年
    - BatchNormalizationの提案 [Sergey Ioffe]
      - 学習の安定化, 高速化, 過学習の抑制に寄与
      - 「バッチ正規化使っていないなら人生損してるで」
    - Adamの提案 [Diederik P. Kingmaら]
      - AdaGrad等の改良アルゴリズム
    - 画風変換 [Leon A. Gatysら]
      - 画像のスタイルを転写
    - DeepDream [Google blogpost]
      - 画像をバケモノのイラストに変換
    - AlphaGo [DeepMind]
      - 囲碁でトップ棋士に勝利
      - CPU1202個, GPU176基




# DeepLearning研究の歴史

- 2000年代の研究
  - 2016年 転移学習への言及 [Andrew Ng, NIPS'16]
    - ある教師データで学習した結果を別の教師データの学習に用いることでより良い精度が望める



# DeepLearning研究の歴史

- ニューラルネットワーク技術の成長



# 特別研究のテーマ

# 特別研究のテーマ

- CNNを用いた音楽のジャンル分類とデータ生成モデルの検討
  - 目的
    - 音楽を自動的にタグ付け出来るような優秀な分類器の作成
    - 音楽データの生成モデルへの応用
    - ニューラルネットワークの効率的な学習の枠組みを提供する
  - 意義
    - 優秀な分類器を作ることで脳が音を認識するメカニズムの解析
    - 音響系の研究に対するサポート
    - 作曲能力の無い人に能力を提供
    - 波形解析の新たなアプローチの提供

# 特別研究のテーマ

- CNNを用いた音楽のジャンル分類とデータ生成モデルの検討
  - 音楽の離散信号データをNon-Stationary Gabor Transformによる振幅スペクトルに変換してCNNの学習データに用いる
  - 画風変換を音楽にも拡張
    - 画風変換には優秀な分類器が必要
    - 画像の画風変換ではVGG-Netを用いている
  - 優秀な分類器を作成する
  - 転移学習のアプローチを採用する
    - 楽器音の識別
    - 楽曲とスピーチの識別
    - 10ジャンルの音楽の識別
    - 50ジャンルの音楽の識別

# 特別研究のテーマ

- CNNを用いた音楽のジャンル分類とデータ生成モデルの検討
  - 学習データには著作権切れのデータを集めたデータセット等を用いる
    - GTZAN 10genre set
      - Marsyas
    - GTZAN music or speech subset
      - Marsyas
    - The NSynth
      - Google DeepMind
    - IRMAS
      - Music Technology Group
    - Million Song Dataset subset
      - labrosa

# 特別研究のテーマ

- CNNを用いた音楽のジャンル分類とデータ生成モデルの検討
  - 先行研究
    - Automatic Tagging Using DeepConvolutional Neural Network[Keunwoo, 2016]
      - CNNを使った自動タグ付けシステム, 精度が低い
    - Convolutional Recurrent Neural Network for Music Classification[Keunwoo, 2016]
      - CRNNを使った自動タグ付けシステム, 学習が遅い, パラメータ量が多い
    - WaveNet: A Generative Model for Raw Audio [Heiga Zen, 2016]
      - オーディオデータ生成モデル, 音と音のつながりが不自然
    - SampleRNN: An Unconditional End-to-End Neural Audio Generation Model[Soroush, 2016]
      - オーディオデータ生成モデル, かなり高精度
    - Transfer Learning for Music Classification and Regression Tasks[Keunwoo, 2017]
      - 転移学習により従来までの認識率を超える, 少ないパラメータで実現, 特徴空間が狭い



# 特別研究のテーマ

- CNNを用いた音楽のジャンル分類とデータ生成モデルの検討
  - 先行研究での課題と認識
    - CNNである程度認識できる
      - 60～80%は達成出来る
    - WaveNetは音と音のつながりが不自然で実用的でない
      - 解決方法が見つかりつつある
    - 転移学習を用いることで良い精度が出せる
    - CRNNよりもCNNのほうが効率が良い
      - CRNNは学習も遅い
    - 使用する波形データは11kHz 8bit, 22.5Hz 8bit等で高精細なデータは生成できない
      - ハードウェアの技術的進歩を待つ他無い

# 特別研究のテーマ

- CNNを用いた音楽のジャンル分類とデータ生成モデルの検討
    - 解決したいこと
      - より高い分類精度
      - より広い特徴空間での実現
        - 画風変換のようなパラメータを利用した応用研究が可能になる
- 音楽のジャンル分類問題だけでなく、その先の応用研究に必要な広大な空間を持つネットワークを作りたい
- 音声認識タスクでも有用である可能性が高い

# 人工知能に関する倫理的主張

# DeepLearning研究の歴史

- 人工知能学会の倫理指針（2017年2月改定）
  - <http://ai-elsi.org/wp-content/uploads/2017/02/人工知能学会倫理指針.pdf>
  - 人類への貢献
    - 人工知能の設計, 開発, 運用には専門家として人類の安全への脅威の排除に努める
  - 法規制の遵守
    - 間接的・直接的に問わず他者に危害を加える意図を持って人工知能を利用しない
    - 知的財産や他者との契約・合意の尊重
  - 他者のプライバシー尊重
    - 人工知能の開発において他者のプライバシーを尊重する
  - 安全性
    - 常に制御可能性, 安全性について留意し, 適切な情報提供・注意喚起を行う
  - 誠実な振る舞い
    - 技術的限界や問題について科学的に真摯に説明を行う